PEMODELAN SPASIAL-TEMPORAL DISPARITAS IPM PROVINSI INDONESIA MELALUI INTEGRASI UMAP-GMM, FIXED EFFECT, XGBOOST, DAN SHAP UNTUK PROYEKSI KEBIJAKAN NASIONAL.docx

by turnitin .com

Submission date: 01-May-2026 03:08PM (UTC+0900)

Submission ID: 2947215240

File name: PEMODELAN_SPASIAL-TEMPORAL_DISPARITAS_IPM_PROVINSI_INDONESIA_MELALUI_INTEGRASI_UMAP-GMM_FIXED_EFFECT_XGBOOST_DAN_SHAP_UNTUK_PROYEKSI_KEBIJAKAN_NASIONAL.docx (427.47K)

Word count: 5213

Character count: 35902

PEMODELAN SPASIAL-TEMPORAL DISPARITAS IPM PROVINSI INDONESIA MELALUI INTEGRASI UMAP-GMM, FIXED EFFECT, XGBOOST, DAN SHAP UNTUK PROYEKSI KEBIJAKAN NASIONAL

Nazril Ravi Pratama[1], Nadia Kaila[2]
[1]Universitas Negeri Surabaya, 24031554129@mhs.unesa.ac.id
[2]Universitas Negeri Surabaya, 24031554109@mhs.unesa.ac.id

ABSTRAK

Abstrak - Indeks Pembangunan Manusia (IPM) merupakan indikator utama dalam mengukur kualitas pembangunan yang sejalan dengan agenda *Sustainable Development Goals* (SDGs), khususnya pengentasan kemiskinan, peningkatan kualitas pendidikan, dan pengurangan kesenjangan wilayah. Meskipun IPM Indonesia menunjukkan tren meningkat, disparitas antarprovinsi masih menjadi tantangan, sehingga diperlukan pendekatan berbasis data yang lebih adaptif. Dengan menggunakan data BPS (Badan Pusat Statistik) tahun 2021–2024, Penelitian ini bertujuan untuk memetakan klaster provinsi, mengidentifikasi determinan IPM, serta memproyeksikan tren IPM 2025–2027 menggunakan pendekatan integratif UMAP–GMM, Fixed Effect Model (FEM), dan XGBoost–SHAP. Hasil penelitian menunjukkan terbentuknya dua klaster utama yang merepresentasikan ketimpangan wilayah barat dan timur Indonesia. Variabel kemiskinan dan pengangguran terbukti sebagai determinan signifikan IPM, sementara analisis SHAP mengungkap perbedaan kontribusi variabel antar klaster. Proyeksi IPM mengidentifikasi fenomena provinsi paradoks (IPM tinggi namun pertumbuhan melambat) dan *underdog* (IPM rendah dengan pertumbuhan tinggi). Temuan ini mendukung arah kebijakan pemerintah dalam transformasi digital dan penguatan perencanaan berbasis bukti, serta relevan dengan sub-tema pembangunan inklusif dan pemerataan wilayah. Solusi yang direkomendasikan meliputi intervensi kebijakan berbasis klaster, penguatan program pengentasan kemiskinan dan penciptaan lapangan kerja, serta optimalisasi Decision Support System (DSS) berbasis dashboard untuk meningkatkan efektivitas pengambilan keputusan pembangunan yang adaptif dan berkelanjutan.

Kata kunci: Indeks Pembangunan Manusia, UMAP–GMM, Fixed Effect Model, SHAP, Kebijakan Berbasis Data

I. PENDAHULUAN

Indeks Pembangunan Manusia (IPM) merupakan indikator krusial dalam mengukur keberhasilan pembangunan suatu negara secara multidimensi, yang mencakup dimensi kesehatan, pendidikan, dan standar hidup layak [1]. Keberhasilan IPM juga menjadi target fundamental dalam agenda *Sustainable Development Goals* (SDGs), khususnya dalam upaya mengakhiri kemiskinan, mengurangi kesenjangan, serta memastikan kualitas pendidikan yang inklusif [2], sekaligus berperan sebagai parameter utama dalam evaluasi kinerja pemerintah daerah dan penentuan alokasi dana transfer pusat [3].

Berdasarkan laporan terbaru Badan Pusat Statistik (BPS), IPM Indonesia pada tahun 2025 telah mencapai angka 75,90, meningkat sebesar 0,88 poin dibandingkan tahun sebelumnya yang sebesar 75,02 [4]. Meskipun menunjukkan tren positif secara agregat nasional, peningkatan tersebut belum diikuti oleh pemerataan kualitas hidup

secara spasial. Disparitas antarprovinsi masih menjadi tantangan struktural yang persisten akibat ketimpangan akses sumber daya antara kawasan barat dan timur Indonesia [5]. Kondisi ini mengisyaratkan perlunya pergeseran menuju strategi intervensi yang lebih presisi dan berbasis bukti data.

Saat ini, evaluasi IPM di Indonesia masih bertumpu pada metode konvensional melalui analisis deskriptif maupun regresi linier sederhana yang mengasumsikan hubungan antarvariabel bersifat konstan [6]. Pendekatan tersebut cenderung kurang mampu menangkap heterogenitas karakteristik wilayah serta interaksi non-linier yang kompleks dalam data sosio-ekonomi [7]. Sejumlah penelitian telah mencoba memetakan IPM menggunakan teknik klasterisasi tradisional seperti K-Means, namun metode ini memiliki keterbatasan dalam menangani data dengan struktur manifold yang kompleks [8].

Untuk menjawab permasalahan tersebut, pemerintah mulai mendorong penguatan pengambilan kebijakan berbasis data melalui pemanfaatan kecerdasan buatan (*Artificial Intelligence*/AI) guna meningkatkan efisiensi dan efektivitas program pembangunan nasional [9]. Sejalan dengan arah tersebut, integrasi teknologi AI menjadi relevan untuk memitigasi risiko kebijakan yang bersifat generik (*one-size-fits-all*), yang sering kali tidak mampu menjawab permasalahan spesifik pada masing-masing klaster wilayah. Namun demikian, penerapan *machine learning* dalam analisis indikator ekonomi masih menghadapi tantangan utama berupa rendahnya interpretabilitas model yang kerap dipersepsikan sebagai "kotak hitam" (*black-box*) [10].

Oleh karena itu, penelitian ini mengusulkan penggunaan algoritma tingkat lanjut berupa *Gaussian Mixture Model* (GMM) [3], [5] yang dikombinasikan dengan teknik reduksi dimensi *Uniform Manifold Approximation and Projection* (UMAP) [11], yang memiliki fleksibilitas lebih tinggi dalam menangani struktur data berdimensi tinggi dan non-linear. Berdasarkan kesenjangan tersebut, studi ini bertujuan untuk memetakan kembali pengelompokan provinsi di Indonesia melalui pendekatan integratif UMAP–GMM guna menangkap profil sosial-ekonomi multidimensi secara lebih akurat dibandingkan metode konvensional.

Analisis selanjutnya diarahkan untuk mengidentifikasi variabel kebijakan yang berpengaruh signifikan terhadap capaian IPM dalam kerangka *Fixed Effect Model*, serta mengevaluasi proyeksi pertumbuhan IPM provinsi untuk periode 2025–2027 dalam rangka mendeteksi wilayah dengan pola pertumbuhan tidak konvensional, termasuk fenomena paradoks maupun wilayah *underdog*. Selain itu, penelitian ini juga mengintegrasikan pendekatan *SHapley Additive exPlanations* (SHAP) untuk mengukur kontribusi masing-masing variabel determinan, sekaligus meningkatkan transparansi dan akuntabilitas model AI yang digunakan.

Sebagai implementasi praktis, seluruh hasil analisis dikembangkan dalam bentuk *Decision Support System* (DSS) berbasis *web dashboard* yang mampu memvisualisasikan data kompleks menjadi informasi yang intuitif bagi pengambil kebijakan. Integrasi metode ini diharapkan menghasilkan klasterisasi provinsi yang lebih stabil dan objektif sebagai dasar penyusunan intervensi kebijakan yang tersegmentasi sesuai karakteristik wilayah, serta mendukung pencapaian target pembangunan berkelanjutan. Melalui

instrumen evaluasi berbasis data tersebut, pemerintah diharapkan dapat memitigasi disparitas pembangunan manusia secara lebih tepat waktu, inklusif, dan berbasis bukti statistik yang kuat.

II. METODE PENELITIAN

2.1 Jenis dan Desain Penelitian

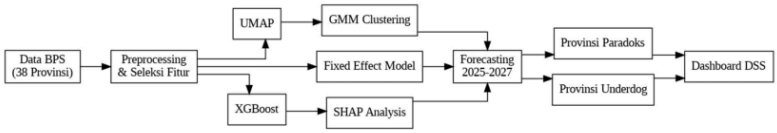

Gambar 1. Diagram Alur Penelitian

Penelitian ini merupakan studi kuantitatif berbasis data dengan pendekatan komputasional yang mengintegrasikan analisis statistik inferensial dan *machine learning* dalam satu kerangka pemodelan terpadu. Secara desain, penelitian ini bersifat deskriptif-prediktif, di mana pendekatan deskriptif digunakan untuk memetakan pengelompokan provinsi berdasarkan kemiripan profil sosial-ekonomi multidimensi serta mengidentifikasi determinan IPM, sedangkan pendekatan prediktif digunakan untuk memproyeksikan tren IPM per provinsi pada periode 2025–2027.

Data yang digunakan merupakan data sekunder berbentuk panel tidak seimbang yang mencakup 38 provinsi di Indonesia dalam rentang waktu 2021 hingga 2024, dengan total 151 observasi. Struktur data panel memungkinkan pengendalian heterogenitas tidak teramati yang bersifat *time-invariant* pada masing-masing provinsi, sekaligus menangkap dinamika perubahan antarwaktu. Alur keseluruhan proses analisis dirangkum dalam Gambar 1.

Pipeline analisis terdiri dari lima tahap utama. Tahap pertama adalah *preprocessing* dan seleksi fitur untuk memastikan kualitas data. Tahap kedua adalah reduksi dimensi menggunakan *Uniform Manifold Approximation and Projection* (UMAP) yang dilanjutkan dengan klasterisasi menggunakan *Gaussian Mixture Model* (GMM) berbasis *soft clustering*. Tahap ketiga hingga kelima mencakup pemodelan lanjutan, yaitu estimasi *Fixed Effect Model* (FEM), pelatihan model *Extreme Gradient Boosting* (XGBoost) dengan interpretasi *SHapley Additive exPlanations* (SHAP), serta proyeksi IPM periode 2025–2027. Seluruh hasil analisis diintegrasikan ke dalam *dashboard* berbasis Streamlit sebagai *Decision Support System* (DSS).

2.2 Data dan Definisi Variabel

Data yang digunakan merupakan data sekunder dari publikasi resmi Badan Pusat Statistik (BPS), meliputi *Indeks Pembangunan Manusia Provinsi*, *Keadaan Ketenagakerjaan Indonesia*, *Profil Kemiskinan Indonesia*, dan *Survei Sosial Ekonomi Nasional*. Data mencakup 38 provinsi pada periode 2021 hingga 2024 dengan total 151 observasi. Ketidakseimbangan data disebabkan oleh tidak tersedianya satu observasi pada tahun 2021.

Variabel penelitian dikelompokkan ke dalam tiga dimensi utama, yaitu pendidikan, ketenagakerjaan, dan kemiskinan. Dimensi pendidikan diwakili oleh Angka Partisipasi Sekolah (APS) usia 13–15, 16–18, dan 19–24 tahun. Dimensi ketenagakerjaan meliputi Tingkat Pengangguran Terbuka (TPT) dan Tingkat Partisipasi Angkatan Kerja (TPAK) periode Februari. Dimensi kemiskinan mencakup garis kemiskinan dan persentase penduduk miskin periode Maret. IPM digunakan sebagai variabel target.

Dua keputusan seleksi variabel dilakukan untuk menjaga validitas model. Pertama, Rata-rata Lama Sekolah (RLS) dan Harapan Lama Sekolah (HLS) dikeluarkan karena keduanya merupakan komponen langsung pembentuk IPM berdasarkan formula resmi BPS. Penyertaan variabel tersebut sebagai prediktor akan menciptakan hubungan tautologis, di mana variabel independen secara mekanis sudah terkandung dalam variabel dependen, sehingga berpotensi menghasilkan koefisien yang bias (*spurious correlation*) dan mengaburkan interpretasi hubungan kausal antar variabel.

Kedua, variabel duplikat berbasis periode pengukuran tidak digunakan karena memiliki korelasi yang sangat tinggi dengan variabel utama pada periode yang berbeda. Kondisi ini berpotensi menimbulkan *multicollinearity*, yang dapat meningkatkan *standard error*, menurunkan stabilitas estimasi, serta menyulitkan interpretasi pengaruh masing-masing variabel. Oleh karena itu, hanya satu representasi waktu yang dipilih untuk setiap indikator guna menjaga efisiensi dan ketepatan model.

Berdasarkan proses seleksi tersebut, diperoleh tujuh variabel input kebijakan yang digunakan secara konsisten dalam seluruh tahapan analisis. Definisi operasional masing-masing variabel disajikan pada Tabel 1.

Tabel 1. Definisi Operasional dan Satuan Variabel Sosio-Ekonomi Tahun 2021–2024

Variabel	Definisi Operasional	Satuan
Angka Partisipasi Sekolah (APS) 13–15 Thn	Proporsi penduduk usia 13–15 tahun yang masih bersekolah	%
Angka Partisipasi Sekolah (APS) 16–18 Thn	Proporsi penduduk usia 16–18 tahun yang masih bersekolah	%
Angka Partisipasi Sekolah (APS) 19–24 Thn	Proporsi penduduk usia 19–24 tahun yang masih bersekolah	%
Tingkat Pengangguran Terbuka (TPT) Feb	Proporsi angkatan kerja yang tidak bekerja dan mencari pekerjaan, Februari	%
Tingkat Partisipasi Angkatan Kerja (TPAK) Feb	Proporsi penduduk usia kerja yang aktif dalam pasar tenaga kerja, Februari	%
Garis Kemiskinan Maret	Nilai pengeluaran minimum per kapita per bulan untuk memenuhi kebutuhan dasar, Maret	Rp/kapita/bulan
Persentase Penduduk Miskin Maret	Proporsi penduduk dengan pengeluaran di bawah garis kemiskinan, Maret	%

2.3 Teknik Analisis Data

2.3.1 Preprocessing dan UMAP

Tahap *preprocessing* diawali dengan penanganan *missing values* menggunakan pendekatan *carry forward* berbasis provinsi, di mana setiap nilai yang hilang diisi menggunakan nilai observasi terakhir yang tersedia dari provinsi yang sama pada periode sebelumnya [12]. Pendekatan ini dipilih karena lebih merepresentasikan dinamika masing-masing wilayah dibandingkan imputasi berbasis rata-rata global yang berpotensi mengaburkan heterogenitas antarprovinsi.

Selanjutnya, dilakukan standarisasi fitur menggunakan *StandardScaler* sehingga setiap variabel memiliki rata-rata nol dan standar deviasi satu. Standarisasi ini diperlukan karena ketujuh fitur input memiliki skala yang berbeda, yaitu persentase untuk variabel pendidikan, ketenagakerjaan, dan kemiskinan, serta satuan rupiah per kapita per bulan untuk garis kemiskinan. Tanpa standarisasi, variabel dengan skala numerik besar berpotensi mendominasi perhitungan jarak Euclidean dan menghasilkan representasi data yang bias [13]. Untuk menghindari *data leakage*, proses *fitting StandardScaler* dilakukan secara eksklusif pada data *cross-section* tahun 2024 sebelum diterapkan pada data lainnya.

Tahap berikutnya adalah reduksi dimensi menggunakan *Uniform Manifold Approximation and Projection* (UMAP) [14]. Metode ini dipilih dibandingkan *Principal Component Analysis* (PCA) karena PCA mengasumsikan hubungan linear dan berfokus pada variansi global, sehingga kurang mampu menangkap struktur klaster non-linear yang umum pada data sosial-ekonomi. Sebaliknya, UMAP mampu mempertahankan struktur lokal dan global secara simultan melalui pendekatan graf berbobot berdimensi rendah [15], serta terbukti efektif sebagai tahap praproses sebelum klasterisasi pada data multidimensi [16].

Dalam penelitian ini, parameter UMAP yang digunakan meliputi *n_neighbors* sebesar 5, *min_dist* sebesar 0,05, *metric* Euclidean, serta *random_state* 42 untuk menjamin reprodusibilitas hasil. Proses ini menghasilkan embedding berdimensi dua yang selanjutnya digunakan sebagai input pada tahap klasterisasi menggunakan Gaussian Mixture Model (GMM).

2.3.2 GMM Clustering

Gaussian Mixture Model (GMM) dipilih sebagai algoritma klasterisasi karena memiliki fleksibilitas yang lebih tinggi dibandingkan K-Means dalam memodelkan distribusi data yang heterogen. K-Means mengasumsikan bentuk klaster yang sferis dan berukuran relatif seragam, sehingga kurang sesuai untuk data sosial-ekonomi antarprovinsi yang cenderung kompleks. Sebaliknya, GMM merupakan model probabilistik generatif yang merepresentasikan data sebagai campuran distribusi Gaussian multivariat dengan kovarian penuh (*full covariance*), sehingga setiap klaster dapat memiliki bentuk, ukuran, dan orientasi yang berbeda [17].

Selain itu, GMM menghasilkan *probability vector* keanggotaan untuk setiap observasi, yang direpresentasikan sebagai *confidence score*. Nilai ini mencerminkan tingkat keyakinan bahwa suatu provinsi termasuk dalam klaster tertentu. Nilai *confidence* yang rendah mengindikasikan bahwa suatu provinsi berada pada batas antar klaster, sehingga memerlukan perhatian kebijakan yang lebih kontekstual dibandingkan provinsi dengan nilai *confidence* tinggi.

Penentuan jumlah klaster optimal dilakukan melalui seleksi model menggunakan *Bayesian Information Criterion* (BIC) pada rentang K=2 hingga K=7, yang memberikan penalti terhadap kompleksitas model untuk mencegah *overfitting* [18]. Hasil seleksi kemudian divalidasi menggunakan *Silhouette Score* dan *Davies-Bouldin Index* untuk mengevaluasi kualitas klaster berdasarkan kohesi intra-klaster dan separasi antar-klaster.

2.3.3 Fixed Effect Model

Fixed Effect Model (FEM) digunakan untuk mengidentifikasi variabel kebijakan yang secara statistik signifikan mempengaruhi IPM dengan mengendalikan seluruh karakteristik provinsi yang tidak berubah sepanjang waktu namun berkorelasi dengan variabel independen (*time-invariant unobserved heterogeneity*), seperti kondisi geografis, modal sosial, dan warisan sejarah pembangunan. FEM bekerja dengan melakukan *demeaning* pada level entitas sehingga estimasi koefisien hanya memanfaatkan variasi *within-province* sepanjang waktu, menghasilkan estimasi yang lebih bersih secara kausal dibanding OLS biasa yang rentan terhadap *omitted variable bias* [19].

Spesifikasi model dinyatakan sebagai:

$$IPM_it = \alpha_i + \beta_1 X_1 it + \ldots + \beta_7 X_7 it + \varepsilon_it,$$

di mana α_i merupakan efek tetap spesifik provinsi, X_it adalah vektor variabel independen, dan ε_it adalah *error term*.

Estimasi *standard error* menggunakan pendekatan *cluster-robust* pada level provinsi untuk mengakomodasi potensi heteroskedastisitas dan korelasi serial dalam data panel. Pendekatan ini dipilih karena mampu menghasilkan estimasi varians yang lebih konsisten dibandingkan metode konvensional [20].

2.3.4 XGBoost dan SHAP

Extreme Gradient Boosting (XGBoost) dipilih sebagai model *machine learning* karena kemampuannya menangkap hubungan non-linear kompleks dan interaksi antar variabel yang tidak dapat ditangkap oleh regresi linear [21]. XGBoost membangun ensemble dari pohon keputusan secara sekuensial di mana setiap pohon baru difokuskan pada koreksi *pseudo-residual* pohon sebelumnya, dengan regularisasi L1 dan L2 untuk mencegah *overfitting*. Parameter yang digunakan adalah 300 estimator, *max_depth* 4, *learning rate* 0,05, *subsample* 0,8, *colsample_bytree* 0,7, regularisasi L1 sebesar 0,5 dan L2 sebesar 1,5, serta *min_child_weight* 3. Validasi silang menggunakan *TimeSeriesSplit* dengan 3 *fold*, bukan *KFold* acak, karena *KFold* acak pada data panel dapat membocorkan informasi masa depan ke dalam set pelatihan dengan memungkinkan model belajar dari data tahun 2024 lalu dievaluasi pada data tahun 2022, yang secara fundamental melanggar kausalitas temporal.

Parameter yang digunakan meliputi 300 *estimator*, *max_depth* sebesar 4, *learning rate* 0,05, *subsample* 0,8, *colsample_bytree* 0,7, serta regularisasi L1 sebesar 0,5 dan L2 sebesar 1,5, dengan *min_child_weight* sebesar 3. Validasi silang dilakukan menggunakan *TimeSeriesSplit* dengan 3 *fold* untuk menjaga konsistensi urutan temporal data dan menghindari kebocoran informasi dari masa depan ke dalam proses pelatihan.

Interpretasi model dilakukan menggunakan *SHapley Additive exPlanations* (SHAP) [22], yang mengukur kontribusi masing-masing variabel terhadap hasil prediksi secara

aditif. SHAP dihitung baik pada tingkat global maupun per klaster, sehingga memungkinkan identifikasi perbedaan determinan IPM antar kelompok provinsi.

2.3.5 Forecasting 2025–2027

Proyeksi IPM dilakukan dalam dua tahap yang dirancang untuk menghasilkan prediksi yang realistis dan bervariasi antar provinsi. Tahap pertama adalah ekstrapolasi fitur: untuk setiap provinsi dan setiap variabel input, tren linear dihitung menggunakan OLS pada data historis 2021–2024, menghasilkan *slope* tren spesifik per provinsi. *Slope* tersebut kemudian di-*damp* secara eksponensial menggunakan faktor 0,7 per langkah waktu ke depan, sehingga proyeksi satu tahun ke depan menggunakan 70% *slope* historis, dua tahun menggunakan 49%, dan tiga tahun menggunakan 34%. *Damping* eksponensial ini mencerminkan peningkatan ketidakpastian seiring jauhnya horizon proyeksi dan kecenderungan tren sosial-ekonomi mengalami perlambatan seiring waktu akibat batas fisiologis variabel dan kendala kelembagaan.

Tahap kedua adalah prediksi IPM: nilai fitur yang sudah diproyeksikan dimasukkan ke model XGBoost global yang telah dilatih pada seluruh data historis untuk menghasilkan prediksi IPM, dengan *clipping* ke rentang [50, 95] sebagai batas realistis berdasarkan rentang empiris IPM provinsi Indonesia. Pendekatan dua tahap ini lebih unggul dibanding ekstrapolasi IPM secara langsung karena memanfaatkan seluruh hubungan non-linear yang sudah dipelajari model dari data historis [23]. Hasil proyeksi kemudian dianalisis menggunakan analisis kuadran untuk mengidentifikasi provinsi paradoks (IPM di atas rata-rata nasional namun laju pertumbuhan proyeksi di bawah rata-rata) dan provinsi *underdog* (IPM di bawah rata-rata namun laju pertumbuhan proyeksi di atas rata-rata) sebagai dasar rekomendasi kebijakan yang terdiferensiasi.

2.4 Pengembangan Web Dashboard Decision Support System

Seluruh hasil analisis dari lima tahap metodologi diintegrasikan ke dalam sebuah *dashboard* interaktif berbasis *Streamlit* yang dirancang sebagai *Decision Support System* (DSS) bagi pengambil kebijakan. Konsep DSS yang digunakan mengacu pada kerangka klasik yang mensyaratkan tiga komponen utama: manajemen data (*database management*), manajemen model (*model management*), dan antarmuka pengguna (*user interface*) [24]. Ketiga komponen tersebut terpenuhi secara lengkap dalam sistem yang dikembangkan: data BPS yang terstruktur berfungsi sebagai lapisan manajemen data, *pipeline* UMAP–GMM–FEM–XGBoost–SHAP berfungsi sebagai lapisan manajemen model, dan *dashboard* Streamlit berfungsi sebagai antarmuka yang dapat dioperasikan secara mandiri oleh pengguna non-teknis. Pengembangan *dashboard* berbasis *framework* Python *open-source* ini sejalan dengan tren pengembangan DSS modern yang mengutamakan aksesibilitas, reproduktibilitas, dan kemampuan pembaruan data secara berkala tanpa memerlukan infrastruktur khusus [25].

Dashboard ini terdiri dari delapan modul yang dapat dieksplorasi secara independen. Modul pertama menampilkan ringkasan eksekutif berisi indikator utama IPM nasional dan distribusi provinsi. Modul kedua menyajikan visualisasi clustering *UMAP–GMM* lengkap dengan profil dan *confidence score* tiap provinsi. Modul ketiga menampilkan peta spasial distribusi cluster dan IPM. Modul keempat berisi hasil *Fixed Effect Model* beserta signifikansi dan interpretasinya. Modul kelima menyajikan *SHAP*

summary plot dan perbandingan *feature importance* antar cluster. Modul keenam menampilkan proyeksi IPM 2025–2027 dalam bentuk tren interaktif. Modul ketujuh memvisualisasikan analisis kuadran *paradoks* dan *underdog*. Modul kedelapan merangkum seluruh temuan menjadi sintesis *insight* lintas metode sebagai dasar rekomendasi kebijakan. Seluruh dashboard dirancang dengan prinsip keterbacaan dan efisiensi kognitif agar memudahkan pengambil kebijakan mengeksplorasi data, membandingkan provinsi, dan memperoleh rekomendasi berbasis bukti tanpa keahlian teknis *machine learning* [26].

III. HASIL DAN PEMBAHASAN

3.1 Eksplorasi Data dan Korelasi

Berdasarkan hasil eksplorasi data, seluruh variabel memiliki jumlah observasi yang konsisten sebanyak 151 dengan variasi yang cukup tinggi antarprovinsi, tercermin dari nilai standar deviasi yang relatif besar pada beberapa indikator seperti garis kemiskinan dan persentase penduduk miskin. Rata-rata IPM tercatat sebesar 72,26 dengan rentang nilai antara 61,40 hingga 83,55, menunjukkan adanya disparitas pembangunan manusia yang signifikan. Variabel pendidikan, khususnya *Angka Partisipasi Sekolah (APS) 13–15 tahun*, memiliki rata-rata tinggi (94,39) dan distribusi yang relatif stabil, sedangkan APS 19–24 tahun menunjukkan variasi yang lebih besar, mengindikasikan ketimpangan akses pendidikan lanjutan antarwilayah**.**

Analisis korelasi menunjukkan bahwa persentase penduduk miskin memiliki hubungan paling kuat dengan IPM dengan koefisien negatif (r = -0,810), menegaskan bahwa peningkatan kemiskinan secara konsisten berkorelasi dengan penurunan kualitas pembangunan manusia. Sebaliknya, variabel pendidikan seperti *APS 13–15 tahun* (r = 0,790) dan *APS 16–18 tahun* (r = 0,540) menunjukkan korelasi positif yang cukup kuat, mengindikasikan peran krusial akses pendidikan dalam meningkatkan IPM. Variabel ketenagakerjaan menunjukkan pola yang lebih kompleks, di mana *TPAK (Tingkat Partisipasi Angkatan Kerja) Februari* berkorelasi negatif (r = -0,520), sementara *TPT (Tingkat Pengangguran Terbuka) Februari* justru menunjukkan korelasi positif moderat (r = 0,470), yang mengindikasikan adanya fenomena struktural dalam pasar tenaga kerja. Sementara itu, *APS 19–24 tahun* memiliki korelasi positif lemah (r = 0,260), dan garis kemiskinan menunjukkan hubungan yang hampir tidak signifikan (r = 0,030), sehingga kontribusinya terhadap variasi IPM relatif kecil. Temuan ini mengindikasikan bahwa faktor kemiskinan dan pendidikan dasar-menengah merupakan determinan utama IPM, sementara variabel lainnya bersifat kontekstual dan memerlukan analisis lanjutan berbasis model inferensial dan *machine learning*.

3.2 Hasil Clustering UMAP-GMM

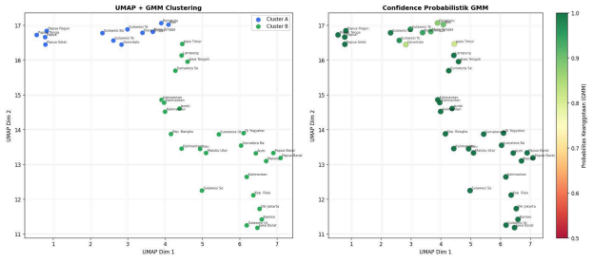

Gambar 2. Scatter Plot hasil UMAP-GMM

Berdasarkan visualisasi pada Gambar 2, hasil embedding *UMAP* menunjukkan pemisahan yang cukup jelas ke dalam dua kelompok utama dalam ruang berdimensi rendah. Dimensi pertama dan kedua mampu merepresentasikan variasi karakteristik sosial-ekonomi secara seimbang, dengan Cluster A terkonsentrasi pada area dimensi pertama yang lebih rendah dan dimensi kedua yang lebih tinggi, sedangkan Cluster B menyebar pada wilayah dengan dimensi pertama yang lebih tinggi dan variasi dimensi kedua yang lebih luas. Pola ini mengindikasikan adanya struktur non-linear dalam data yang berhasil ditangkap dengan baik oleh *UMAP*.

Hasil clustering menggunakan *Gaussian Mixture Model (GMM)* mempertegas pemisahan tersebut dengan menghasilkan dua kelompok yang relatif terpisah tanpa banyak *overlap*. Hal ini juga didukung oleh visualisasi *confidence probabilistik* yang menunjukkan bahwa sebagian besar provinsi memiliki tingkat keanggotaan yang sangat tinggi, sehingga hasil clustering dapat dikatakan stabil dan tidak ambigu. Beberapa titik dengan confidence lebih rendah mengindikasikan adanya wilayah dengan karakteristik transisional yang berada di batas antar cluster.

Tabel 2. Distribusi Anggota Cluster Hasil *UMAP–GMM*

Cluster A (n=12)	Cluster B (n=26)
Bali, Bengkulu, Sulawesi Tenggara, Nusa Tenggara Barat, Sulawesi Tengah, Gorontalo, Sulawesi Barat, Nusa Tenggara Timur, Papua, Papua Selatan, Papua Tengah, Papua Pegunungan	DKI Jakarta, DI Yogyakarta, Kep. Riau, Kalimantan Timur, Banten, Sumatera Barat, Sumatera Utara, Sulawesi Utara, Riau, Aceh, Kalimantan Selatan, Jawa Timur, Sulawesi Selatan, Jawa Barat, Kep. Bangka Belitung, Kalimantan Tengah, Jambi, Jawa Tengah, Sumatera Selatan, Kalimantan Utara, Maluku, Lampung, Maluku Utara, Kalimantan Barat, Papua Barat, Papua Barat Daya

Distribusi anggota cluster pada Tabel 2 menunjukkan perbedaan yang cukup kontras antar kelompok. Cluster A didominasi oleh provinsi dengan tingkat IPM lebih rendah dan persentase kemiskinan lebih tinggi, yang sebagian besar berasal dari kawasan Indonesia timur. Sebaliknya, Cluster B mencakup mayoritas provinsi dengan tingkat pembangunan yang lebih maju dan kondisi sosial-ekonomi yang relatif lebih baik. Dari sisi indikator, Cluster B menunjukkan capaian yang lebih tinggi pada variabel

pendidikan, khususnya *APS 13–15 tahun* dan *APS 16–18 tahun*, sementara Cluster A cenderung tertinggal pada indikator tersebut.

Secara keseluruhan, konsistensi antara pola visual pada Gambar 2 dan distribusi anggota pada Tabel 2 menunjukkan bahwa pendekatan *UMAP–GMM* mampu menghasilkan segmentasi wilayah yang tidak hanya jelas secara statistik, tetapi juga relevan secara substantif dalam menggambarkan ketimpangan pembangunan antarprovinsi di Indonesia.

3.3 Hasil Fixed Effect Model

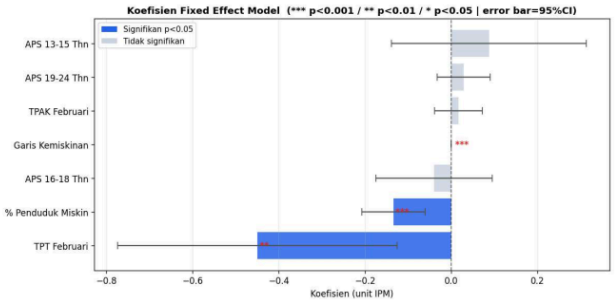

Gambar 3. Koefisien *Fixed Effect Model* terhadap IPM dengan interval kepercayaan 95% dan tingkat signifikansi variabel

Berdasarkan hasil estimasi pada Gambar 3, *Fixed Effect Model (FEM)* digunakan untuk mengidentifikasi pengaruh variabel kebijakan terhadap IPM dengan mengendalikan heterogenitas spesifik antarprovinsi (*within-province effect*). Secara umum, hasil menunjukkan bahwa tidak seluruh variabel memiliki pengaruh yang signifikan secara statistik. Dari tujuh variabel yang diuji, hanya tiga variabel yang terbukti signifikan, yaitu *TPT Februari*, persentase penduduk miskin, dan garis kemiskinan. Visualisasi koefisien pada Gambar 3 memperlihatkan bahwa kedua variabel pertama memiliki arah pengaruh negatif terhadap IPM, sedangkan garis kemiskinan menunjukkan pengaruh positif meskipun dengan skala yang sangat kecil. Sementara itu, variabel pendidikan seperti *APS 13–15 tahun*, *APS 16–18 tahun*, dan *APS 19–24 tahun*, serta *TPAK Februari*, tidak menunjukkan signifikansi statistik, yang mengindikasikan bahwa variasi perubahan IPM dalam periode pengamatan lebih banyak dijelaskan oleh faktor ekonomi dibandingkan faktor partisipasi pendidikan dalam kerangka model ini.

Secara lebih spesifik, peningkatan *TPT Februari* sebesar satu satuan berasosiasi dengan penurunan IPM sebesar 0,4494 poin ($p < 0{,}01$), menunjukkan bahwa kenaikan pengangguran memiliki dampak negatif yang cukup besar terhadap kualitas pembangunan manusia. Selain itu, peningkatan persentase penduduk miskin juga secara signifikan menurunkan IPM sebesar 0,1346 poin ($p < 0{,}001$), yang menegaskan bahwa kemiskinan merupakan determinan utama dalam menjelaskan disparitas IPM antarprovinsi. Di sisi lain, garis kemiskinan menunjukkan koefisien positif dan signifikan secara statistik, namun dengan nilai yang sangat kecil, sehingga secara substantif lebih

merefleksikan perbedaan standar biaya hidup antarwilayah dibandingkan dampak langsung terhadap peningkatan kesejahteraan. Secara keseluruhan, hasil ini mengindikasikan bahwa faktor struktural ekonomi, khususnya pengangguran dan kemiskinan, memainkan peran dominan dalam dinamika perubahan IPM, sementara variabel lain bersifat komplementer dan memerlukan pendekatan analisis lanjutan untuk menangkap pengaruhnya secara lebih komprehensif.

3.4 Hasil SHAP dan Feature Importance

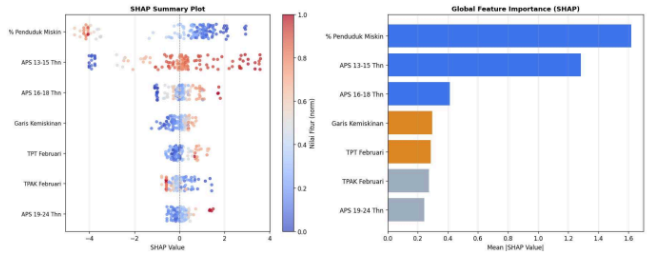

Gambar 4. Visualisasi *SHAP summary plot* dan *global feature importance* dalam menjelaskan kontribusi variabel terhadap prediksi IPM

Berdasarkan visualisasi pada Gambar 4, interpretasi model menggunakan *SHapley Additive Explanations (SHAP)* menunjukkan kontribusi masing-masing variabel terhadap prediksi IPM, baik secara global maupun pada level observasi. *SHAP summary plot* memperlihatkan distribusi pengaruh setiap fitur, di mana posisi horizontal menunjukkan besar dan arah kontribusi, sedangkan warna merepresentasikan nilai fitur. Secara umum, persentase penduduk miskin dan *APS 13–15 tahun* memiliki sebaran nilai *SHAP* paling luas, sehingga menjadi variabel paling dominan. Nilai tinggi pada persentase penduduk miskin cenderung menurunkan IPM, sedangkan nilai tinggi pada *APS 13–15 tahun* meningkatkan IPM, konsisten dengan hasil analisis sebelumnya.

Hasil *global feature importance* menegaskan bahwa persentase penduduk miskin merupakan variabel paling berpengaruh, diikuti *APS 13–15 tahun* dan *APS 16–18 tahun*. Variabel lain seperti garis kemiskinan, *TPT Februari*, dan *TPAK Februari* memiliki kontribusi moderat, sedangkan *APS 19–24 tahun* paling rendah. Pada tingkat cluster, Cluster A didominasi oleh *APS 13–15 tahun* dan persentase penduduk miskin dengan pengaruh yang lebih kuat, sedangkan pada Cluster B pengaruh variabel lebih merata dengan persentase penduduk miskin tetap sebagai faktor utama. Secara keseluruhan, hasil *SHAP* menunjukkan bahwa determinan IPM bersifat berbeda antar cluster, sehingga kebijakan perlu disesuaikan dengan karakteristik masing-masing wilayah.

3.5 Proyeksi IPM 2025–2027 dan Analisis Paradoks-Underdog

Hasil proyeksi IPM periode 2025–2027 menunjukkan variasi yang bermakna antar provinsi dengan delta perubahan berkisar antara −3,025 hingga +5,142 poin,

mencerminkan perbedaan nyata tren sosial-ekonomi historis antar wilayah. Cluster B memproyeksikan rata-rata IPM 2027 sebesar 74,224 dengan standar deviasi 2,677, sedangkan Cluster A memproyeksikan rata-rata 70,160 dengan standar deviasi yang lebih besar yakni 4,124 mengindikasikan heterogenitas internal yang lebih tinggi dalam kelompok ini. Lima provinsi dengan proyeksi IPM tertinggi pada tahun 2027 seluruhnya berasal dari Cluster B, yaitu DKI Jakarta (80,614), DI Yogyakarta (80,205), Kepulauan Riau (78,840), Kalimantan Timur (78,193), dan Bali (77,574). Sebaliknya, lima provinsi dengan proyeksi terendah didominasi oleh provinsi-provinsi Papua dalam Cluster A, yaitu Papua Pegunungan (64,105), Papua Tengah (64,121), Papua Selatan (67,375), Papua (68,152), dan Nusa Tenggara Timur (68,361), yang mencerminkan kesenjangan pembangunan manusia antara wilayah barat dan timur Indonesia yang belum menunjukkan konvergensi signifikan dalam horizon tiga tahun ke depan. Secara nasional, rata-rata IPM diproyeksikan mengalami kenaikan tipis dari 72,76 pada tahun 2024 menjadi sekitar 72,95 pada tahun 2027, dengan rata-rata delta sebesar 0,186 poin.

Analisis paradoks mengidentifikasi 22 provinsi yang memiliki IPM 2024 di atas rata-rata nasional (72,76) namun laju pertumbuhan proyeksi berada di bawah rata-rata delta (0,186 poin). Temuan ini secara konsisten didominasi oleh provinsi-provinsi Cluster B yang selama ini dikenal sebagai wilayah maju. Sulawesi Selatan mencatat delta paling negatif sebesar −3,025 disusul DKI Jakarta (−2,936), menunjukkan potensi perlambatan pembangunan yang paling tajam di antara seluruh provinsi. Provinsi-provinsi seperti Aceh (−1,447), Sumatera Utara (−1,039), Kalimantan Tengah (−1,025), Jawa Timur (−1,000), DI Yogyakarta (−0,885), dan Sulawesi Utara (−0,854) turut masuk dalam kategori paradoks meskipun selama ini dipandang sebagai provinsi dengan modal pembangunan yang memadai. Kondisi ini mengindikasikan bahwa provinsi-provinsi tersebut mungkin sedang mengalami hambatan struktural yang membatasi akselerasi pembangunan manusianya, seperti keterbatasan dalam perluasan akses pendidikan tinggi, tekanan pengangguran terbuka yang belum terselesaikan, atau stagnasi daya beli riil masyarakat yang tidak sebanding dengan pertumbuhan garis kemiskinan daerah. Fenomena paradoks ini penting untuk diantisipasi secara kebijakan karena menunjukkan bahwa IPM yang sudah tinggi tidak serta-merta menjamin keberlanjutan pertumbuhan tanpa adanya intervensi yang tepat dan berkelanjutan.

Analisis *underdog* mengidentifikasi 11 provinsi yang memiliki IPM 2024 di bawah rata-rata nasional namun memproyeksikan laju pertumbuhan di atas rata-rata delta, hampir seluruhnya berasal dari wilayah Indonesia bagian timur dan tengah. Papua mencatat delta tertinggi sebesar +5,142 disusul Papua Selatan (+4,365), Papua Barat Daya (+4,003), Maluku Utara (+2,802), dan Nusa Tenggara Barat (+2,078), kelimanya menunjukkan momentum pembangunan yang sangat kuat meski dari *baseline* yang rendah. Papua Barat (+1,381), Papua Tengah (+1,111), Papua Pegunungan (+1,095), Maluku (+0,911), Kalimantan Barat (+0,743), dan Lampung (+0,506) melengkapi daftar provinsi *underdog* dengan potensi *catch-up* yang nyata terhadap rata-rata nasional. Temuan ini mengimplikasikan bahwa kebijakan pembangunan yang tengah berjalan di provinsi-provinsi tersebut baik melalui program otonomi khusus, percepatan pembangunan infrastruktur, maupun ekspansi layanan pendidikan dan kesehatan mulai menunjukkan dampak yang terukur secara proyektif. Provinsi-provinsi *underdog* ini merupakan kandidat prioritas untuk penguatan alokasi anggaran pembangunan jangka menengah, karena kapasitas absorpsi kebijakan yang tinggi dan potensi peningkatan IPM

yang signifikan dalam horizon waktu yang relatif singkat dapat memberikan dampak distribusional terbesar terhadap pemerataan pembangunan manusia di Indonesia.

IV. KESIMPULAN

Penelitian ini menunjukkan bahwa pendekatan integratif berbasis UMAP–GMM, Fixed Effect Model (FEM), serta XGBoost–SHAP mampu memberikan analisis yang lebih komprehensif dalam mengkaji dinamika Indeks Pembangunan Manusia (IPM) di Indonesia. Hasil penelitian mengidentifikasi dua klaster utama yang merepresentasikan ketimpangan struktural antarwilayah, serta menegaskan bahwa faktor ekonomi, khususnya pengangguran dan kemiskinan, merupakan determinan signifikan terhadap IPM. Selain itu, proyeksi periode 2025–2027 mengungkap adanya fenomena provinsi paradoks dengan risiko perlambatan pertumbuhan, serta provinsi underdog dengan potensi akselerasi yang tinggi. Temuan ini menjawab rumusan masalah bahwa metode konvensional belum mampu menangkap heterogenitas dan pola non-linear dalam data pembangunan manusia.

Secara implikatif, penelitian ini merekomendasikan pergeseran kebijakan menuju pendekatan berbasis klaster yang lebih tersegmentasi dan adaptif. Provinsi dengan karakteristik paradoks memerlukan intervensi untuk menjaga keberlanjutan pertumbuhan, sedangkan provinsi underdog perlu diprioritaskan melalui program akseleratif yang berfokus pada peningkatan akses pendidikan dan pengentasan kemiskinan. Seluruh hasil analisis diimplementasikan dalam Decision Support System (DSS) berbasis web yang dapat diakses melalui tautan https://nazril-nadia-wisepapercompetition.streamlit.app/ sebagai instrumen pendukung pengambilan keputusan yang berbasis data, transparan, dan kontekstual. Implementasi model dan kode analisis juga disediakan secara terbuka melalui repositori https://github.com/zrll-shesh/nazril-nadia-wisepaper.git untuk mendukung transparansi dan replikasi. Dengan demikian, penelitian ini tidak hanya memberikan kontribusi akademik, tetapi juga menawarkan solusi praktis yang mendukung transformasi kebijakan pembangunan serta pencapaian tujuan pembangunan berkelanjutan.

DAFTAR PUSTAKA

[1] P. Dewangga, Z. Saenong, and L. O. M. A. Samrin, "Analysis of Regional Inequality in Southeast Sulawesi," *Ecotechnopreneur*, vol. 4, no. 2, pp. 104-118, 2025.

[2] LPPM UNIMMA, "Apa Itu SDGs?," *Lembaga Penelitian dan Pengabdian pada Masyarakat*, [Online]. Available: https://lppm.unimma.ac.id/sdgs/apa-itu-sdgs/.

[3] Y. Zhang et al., "Gaussian Mixture Model Clustering with Incomplete Data," *IEEE Transactions on Knowledge and Data Engineering*, 2021.

[4] Badan Pusat Statistik, "Indeks Pembangunan Manusia (IPM) Indonesia Tahun 2025 Mencapai 75,90," Berita Resmi Statistik, No. 84/11/Th. XXVIII, 5 November 2025.

[5] F. Wang, F. Liao, Y. Li, and H. Wang, "A new prediction strategy for dynamic multi-objective optimization using Gaussian Mixture Model," *Information Sciences*, vol. 580, pp. 331-351, 2021.

[6] H. Wang, Q. Liang, J. T. Hancock, and T. M. Khoshgoftaar, "Feature selection strategies: a comparative analysis of SHAP-value and importance-based methods," *Journal of Big Data*, vol. 11, no. 44, 2024.

[7] H. Lamane et al., "Interpreting machine learning models based on SHAP values in predicting suspended sediment concentration," *International Journal of Sediment Research*, vol. 40, pp. 91-107, 2025.
[8] Kemenko Perekonomian RI, "Perkuat Pengambilan Kebijakan Berbasis Data, Pemerintah Manfaatkan Kecerdasan Buatan," *Publikasi Eksekutif*, 2024. [Online]. Available: https://www.ekon.go.id/publikasi/detail/6544/.
[9] V. V. Baligodugula and F. Amsaad, "Unsupervised Learning: Comparative Analysis of Clustering Techniques on High-Dimensional Data," *arXiv preprint arXiv:2503.23215*, 2025.
[10] N. Aoki, T. Tatsumi, G. Naruse, and K. Maeda, "Explainable AI for government: Does the type of explanation matter?," *Government Information Quarterly*, vol. 41, 2024.
[11] A. Diaz-Papkovich, L. Anderson-Trocmé, and S. Gravel, "A review of UMAP in population genetics," *Journal of Human Genetics*, vol. 66, pp. 85-91, 2021.
[12] A. Jemere, R. Roijers, F. Heuberger, K. Vanhoof, dan J. Wets, "A Survey on Missing Data in Machine Learning," *Journal of Big Data*, vol. 8, no. 140, 2021. doi: 10.1186/s40537-021-00516-9.
[13] C. Wongoutong, "The Impact of Neglecting Feature Scaling in K-Means Clustering," *PLOS ONE*, vol. 19, no. 12, e0310839, Des. 2024. doi: 10.1371/journal.pone.0310839.
[14] L. McInnes, J. Healy, N. Saul, dan L. Großberger, "UMAP: Uniform Manifold Approximation and Projection," *Journal of Open Source Software*, vol. 3, no. 29, p. 861, 2018. doi: 10.21105/joss.00861.
[15] J. Healy dan L. McInnes, "Uniform Manifold Approximation and Projection," *Nature Reviews Methods Primers*, vol. 4, no. 1, p. 82, Nov. 2024. doi: 10.1038/s43586-024-00363-x.
[16] J. M. Aceituno-Aceituno, A. J. Cabezas-García, dan F. Sarabia-Alegría, "Clustering of Countries Through UMAP and K-Means: A Multidimensional Analysis of Development, Governance, and Logistics," *Logistics*, vol. 9, no. 3, p. 108, 2025. doi: 10.3390/logistics9030108.
[17] S. R. Kasa dan V. Rajan, "Avoiding Inferior Clusterings with Misspecified Gaussian Mixture Models," *Scientific Reports*, vol. 13, no. 19164, Nov. 2023. doi: 10.1038/s41598-023-44608-3.
[18] Y. He, Y. He, Z. Zhan, et al., "A Novel Subspace-Based GMM Clustering Ensemble Algorithm for High-Dimensional Data," *Chinese Journal of Electronics*, vol. 34, no. 2, pp. 612–629, 2025. doi: 10.23919/cje.2023.00.153.
[19] J. M. Wooldridge, *Econometric Analysis of Cross Section and Panel Data*, 2nd ed. Cambridge: MIT Press, 2010.
[20] A. Cerqua, M. Letta, dan G. Pinto, "On the (Mis)Use of Machine Learning with Panel Data," *arXiv preprint*, arXiv:2411.09218, Nov. 2024.
[21] T. Chen dan C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining*, San Francisco, 2016, pp. 785–794. doi: 10.1145/2939672.2939785.
[22] S. M. Lundberg dan S.-I. Lee, "A Unified Approach to Interpreting Model Predictions," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.

[23] S. Raj Malla, S. Kayastha, R. Suwal, H. C. Bhandari, dan R. Adhikari, "XGBoost Forecasting of NEPSE Index Log Returns with Walk Forward Validation," *arXiv preprint*, arXiv:2601.08896, 2025.
[24] R. H. Sprague Jr. dan E. D. Carlson, *Building Effective Decision Support Systems*. Englewood Cliffs: Prentice-Hall, 1982.
[25] T. A. Majid, A. N. Alias, dan M. F. Zawawi, "Development of an Interactive Data-Driven Decision Support System Using Python and Streamlit for Regional Development Planning," *Journal of Positive School Psychology*, vol. 6, no. 8, pp. 4561–4572, 2022.
[26] E. Vanhoof, F. Depaire, R. Braekers, dan M. Vander Elst, "Toward Human-Centered Explainable AI Dashboards for Decision Support in Public Policy," *Government Information Quarterly*, vol. 41, no. 1, p. 101889, Jan. 2024. doi: 10.1016/j.giq.2023.101889.

PEMODELAN SPASIAL-TEMPORAL DISPARITAS IPM PROVINSI INDONESIA MELALUI INTEGRASI UMAP-GMM, FIXED EFFECT, XGBOOST, DAN SHAP UNTUK PROYEKSI KEBIJAKAN NASIONAL.docx

ORIGINALITY REPORT

10%	7%	5%	2%
SIMILARITY INDEX	INTERNET SOURCES	PUBLICATIONS	STUDENT PAPERS

PRIMARY SOURCES

1	siperindu.online Internet Source	1%
2	Submitted to Universitas Amikom Student Paper	1%
3	Tri Asmeli Sembiring. "Pengaruh Pendapatan Asli Daerah (PAD), Dana Alokasi Umum (DAU), dan Dana Alokasi Khusus (DAK) Fisik terhadap Pembangunan Manusia di Provinsi Sumatera Utara (Periode 2016 – 2018)", Indonesian Treasury Review Jurnal Perbendaharaan Keuangan Negara dan Kebijakan Publik, 2020 Publication	1%
4	mafiadoc.com Internet Source	1%
5	www.mdpi.com Internet Source	1%
6	www.researchgate.net Internet Source	<1%
7	Tirta Purnaraga, Sifriyani Sifriyani, Surya Prangga. "REGRESI NONPARAMAETRIK SPLINE PADA DATA LAJU PERTUMBUHAN EKONOMI DI KALIMANTAN", BAREKENG: Jurnal Ilmu Matematika dan Terapan, 2020 Publication	<1%

8	docobook.com Internet Source	<1 %
9	Submitted to UPN Veteran Yogyakarta Student Paper	<1 %
10	www.yumpu.com Internet Source	<1 %
11	Submitted to UIN Raden Intan Lampung Student Paper	<1 %
12	Submitted to Universitas Pancasila Student Paper	<1 %
13	Risna Yusuf, Tajerin Tajerin. "KONTRIBUSI PERMINTAAN AKHIR DAN TEKNOLOGI TERHADAP PERUBAHAN OUTPUT SEKTOR PERIKANAN Pendekatan Analisis Input Output", Jurnal Sosial Ekonomi Kelautan dan Perikanan, 2017 Publication	<1 %
14	kaltim.bps.go.id Internet Source	<1 %
15	www.beritadaerah.co.id Internet Source	<1 %
16	Prem Chand Muraharirao, B.V.N.P. Kambhammettu, Chandramouli Sangamreddi, Ramdas Pinninti. "Sequential Gaussian mixtures for transient hydraulic tomography in fractured aquifers", Journal of Hydrology, 2025 Publication	<1 %
17	data.goodstats.id Internet Source	<1 %
18	doczz.net Internet Source	<1 %

19	eprints.upj.ac.id Internet Source	<1 %
20	feb.ugm.ac.id Internet Source	<1 %
21	id.scribd.com Internet Source	<1 %
22	peraturan.bpk.go.id Internet Source	<1 %
23	repository.its.ac.id Internet Source	<1 %
24	www.cloudcomputing.id Internet Source	<1 %
25	123dok.com Internet Source	<1 %
26	Julas Widiasari, Heriberta Heriberta, Hardiani Hardiani. "The Effect of Population, Human Development Index, Access to Proper Sanitation, and Access to Safe Drinking Water on Absolute Poverty in Jambi Province", Jurnal Prajaiswara, 2026 Publication	<1 %
27	Yasir Hasan. "PENGUKURAN SILHOUETTE SCORE DAN DAVIES-BOULDIN INDEX PADA HASIL CLUSTER K-MEANS DAN DBSCAN", Jurnal Informatika dan Teknik Elektro Terapan, 2024 Publication	<1 %
28	es.scribd.com Internet Source	<1 %
29	mdpi-res.com Internet Source	<1 %
	retnn-19.medium.com	

30	Internet Source	<1 %
31	text-id.123dok.com Internet Source	<1 %
32	zums.ac.ir Internet Source	<1 %
33	Güneş, Canan. "Panel Veri Kesikli Tercih Modelleri Ile Türkiye'de Işgücüne Katılım Kararının Analizi", Dokuz Eylul Universitesi (Turkey), 2024 Publication	<1 %
34	Hayatun Nufus SL, Septria Susanti, Ariyun Anisah, Cahya Agung Mulyana. "Strategi Pemerintah dalam Pembangunan Manusia untuk Meningkatkan Perekonomian di Kabupaten Aceh Besar", Jurnal Pendidikan Tambusai, 2026 Publication	<1 %

Exclude quotes	Off	Exclude matches	Off
Exclude bibliography	On		